CM4 : Variance et Biais

Léo Planche

Généralisation

Pour le moment que ce soit pour la régression linéaire ou le perceptron, on a minimisé une fonction de loss :

$$\mathcal{L}(\Theta, X_{train}, Y_{train})$$

C'est à dire que l'on a appris à prédire le label / la valeur associée à des données dont on connaissait déjà la vérité.

Ce que l'on souhaite réellement est de prédire ces valeurs pour de nouvelles données. On veut que notre modèle **généralise** à de nouvelles données.

Est ce toujours possible ? (Non)

Overfitting, définition intuitive

Comment modéliser au mieux N points ?

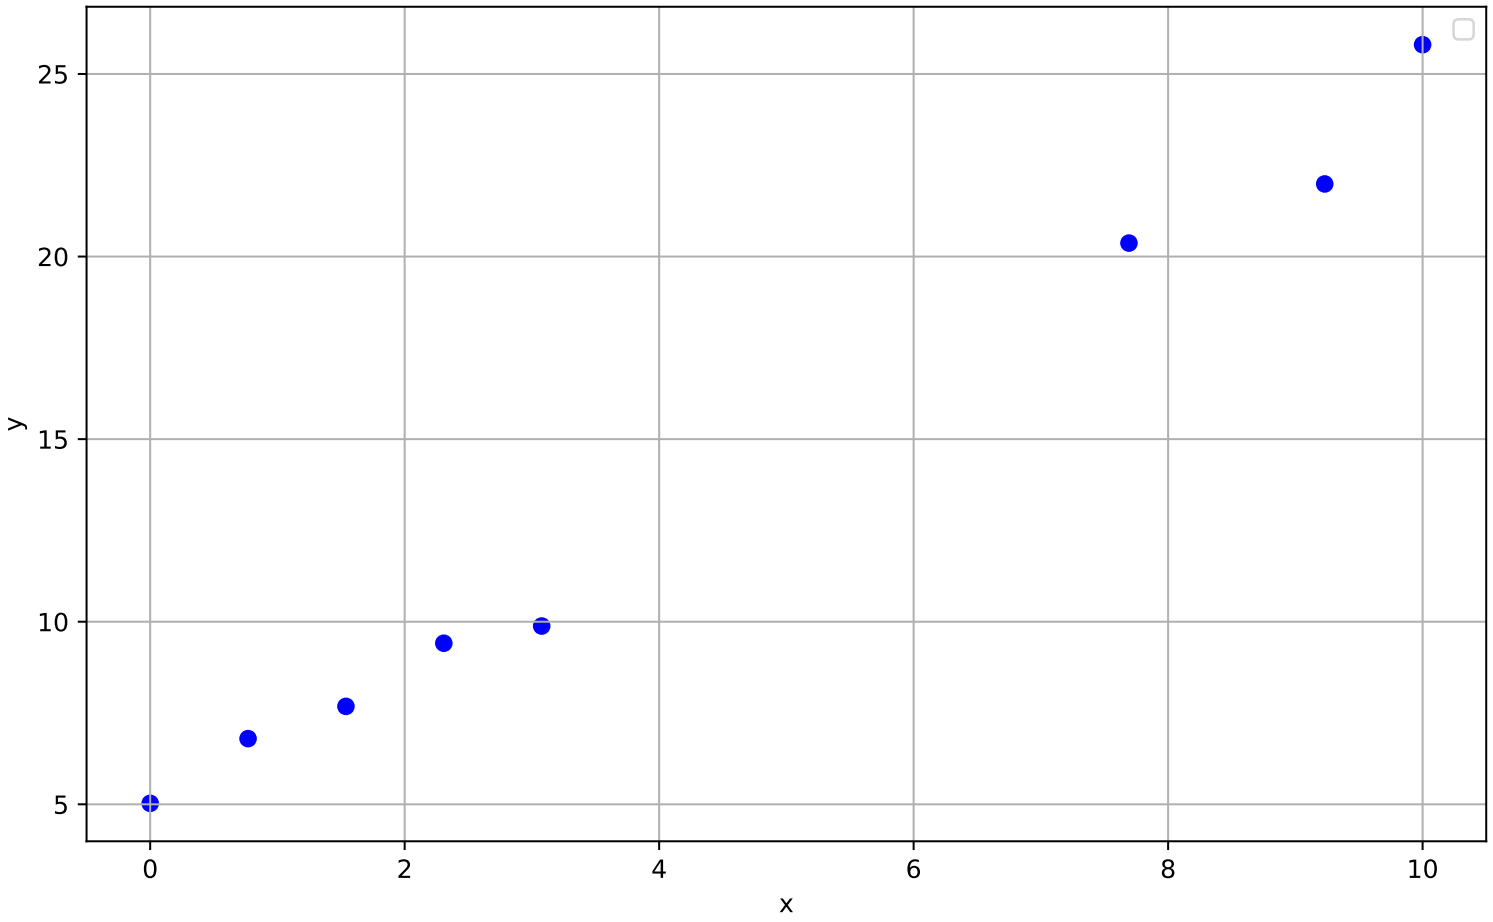

Overfitting, définition intuitive

Comment modéliser au mieux N points ?
Théorème d'intérpolation (Taylor-Lagrange) : pour tout N points on peut trouver un polynome de degré N-1 qui passe par ces N points.

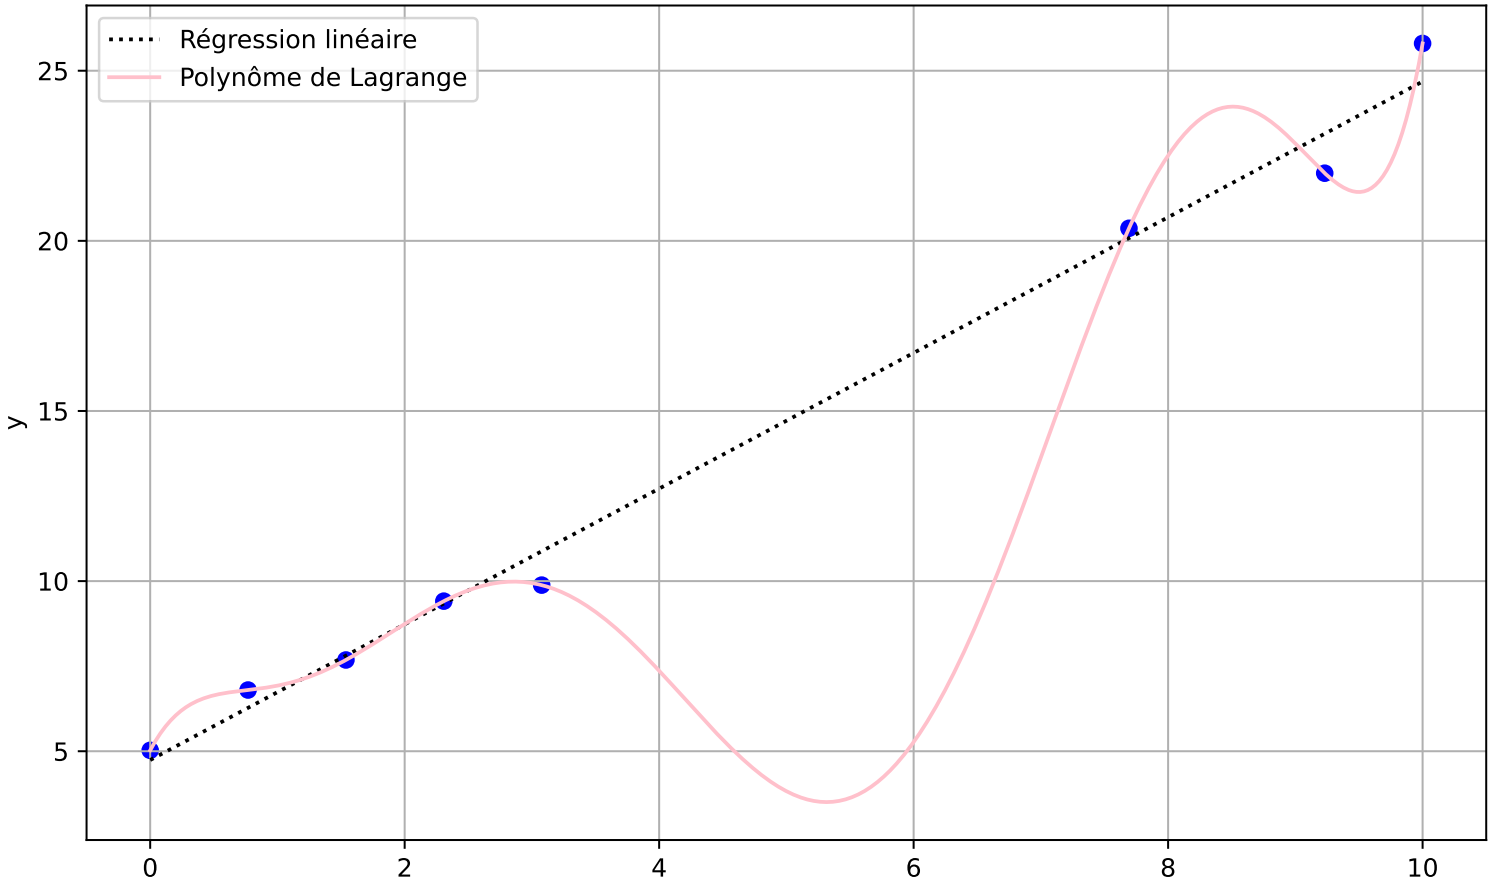

Overfitting, définition intuitive

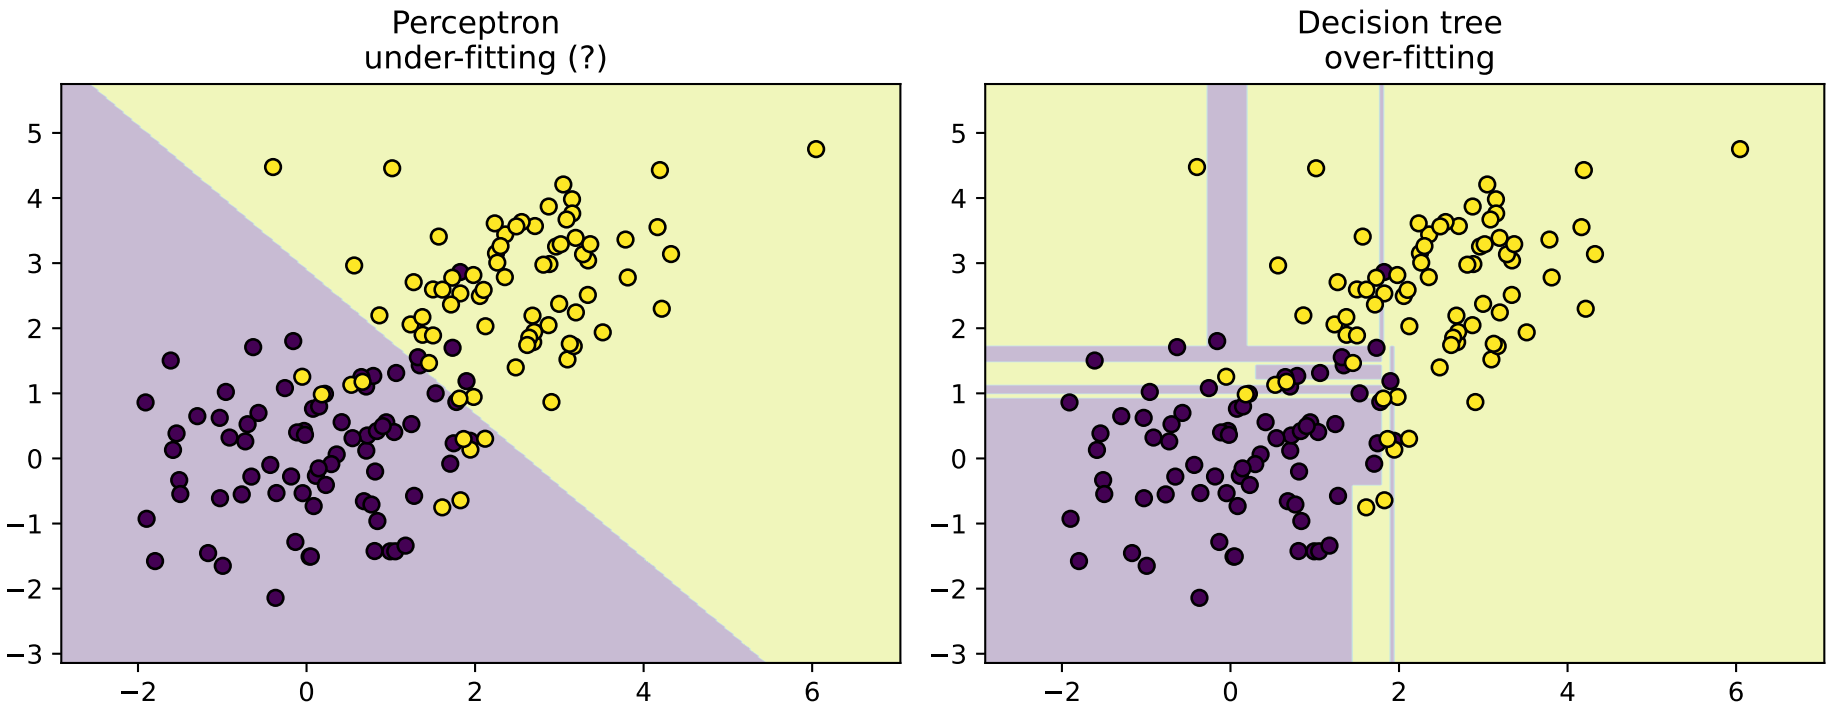

Mesurer l'Overfitting : Test set

On souhaite que notre modèle généralise à de nouvelles données, comment mesurer cela ?

On possède des données X :

- On découpe nos données en une partie X_{train} et une partie X_{test}.
- On entraine notre modèle avec les données X_{train}.
- On mesure les performances de notre modèle sur les données X_{test} qui font office de "nouvelles données".

Mesurer l'overfitting : Test set

Un modèle est performant si il fait peu d'erreurs. Puisque l'on a entrainé le modèle sur X_{train}, sa performance sera (presque) toujours meilleure sur X_{train} que sur X_{test}.

La différence entre la performance du modèle sur le jeu de **train** et le jeu de **test** est une mesure de l'overfitting. Plus cette différence est élevée plus l'overfitting est grand.

Mesurer l'overfitting : Test set

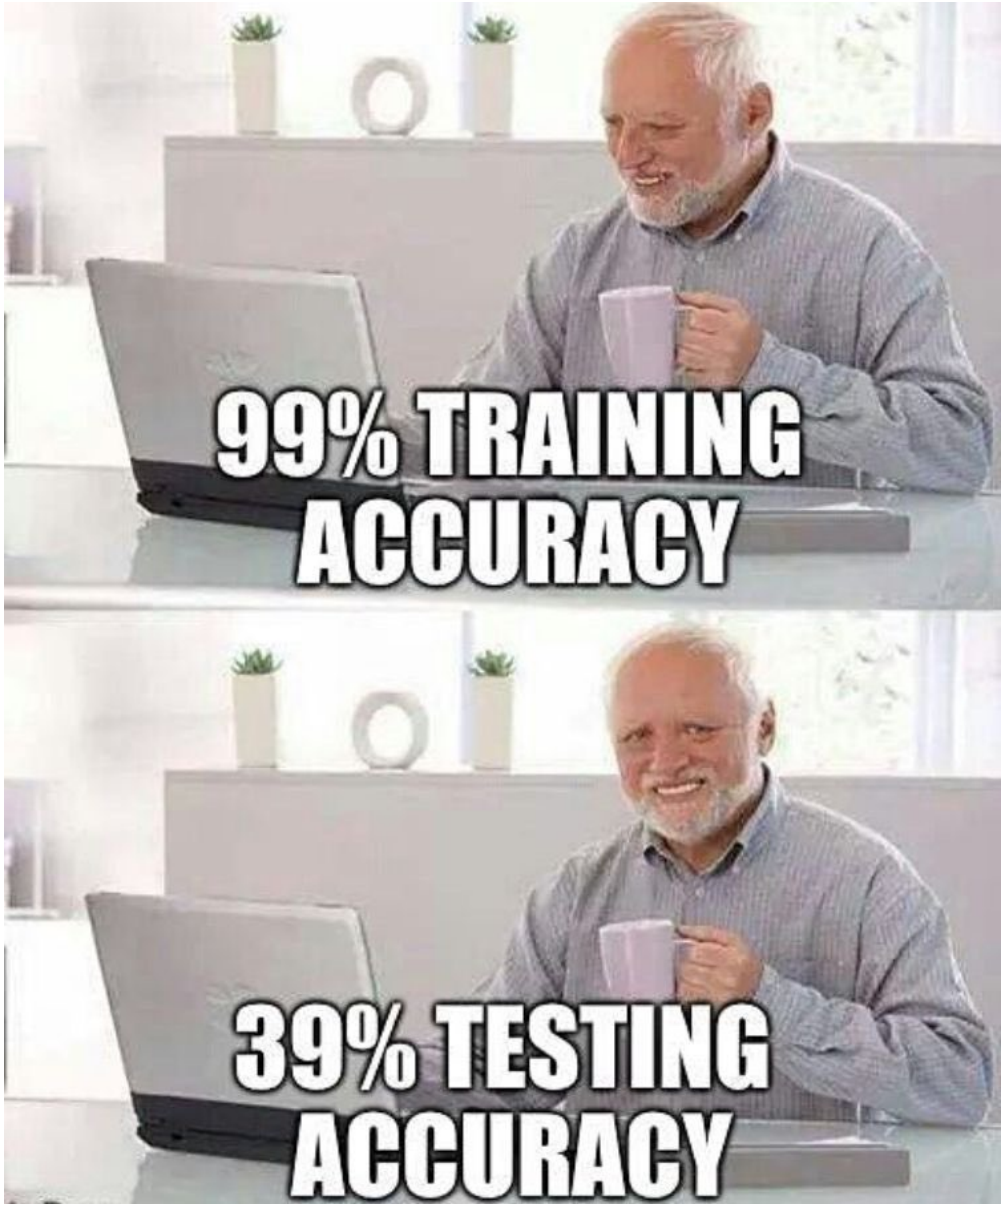

Mesurer l'overfitting : Test set

La différence entre la performance du modèle sur le jeu de **train** et le jeu de **test** est une mesure de l'overfitting. Plus cette différence est élevée plus l'overfitting est grand.

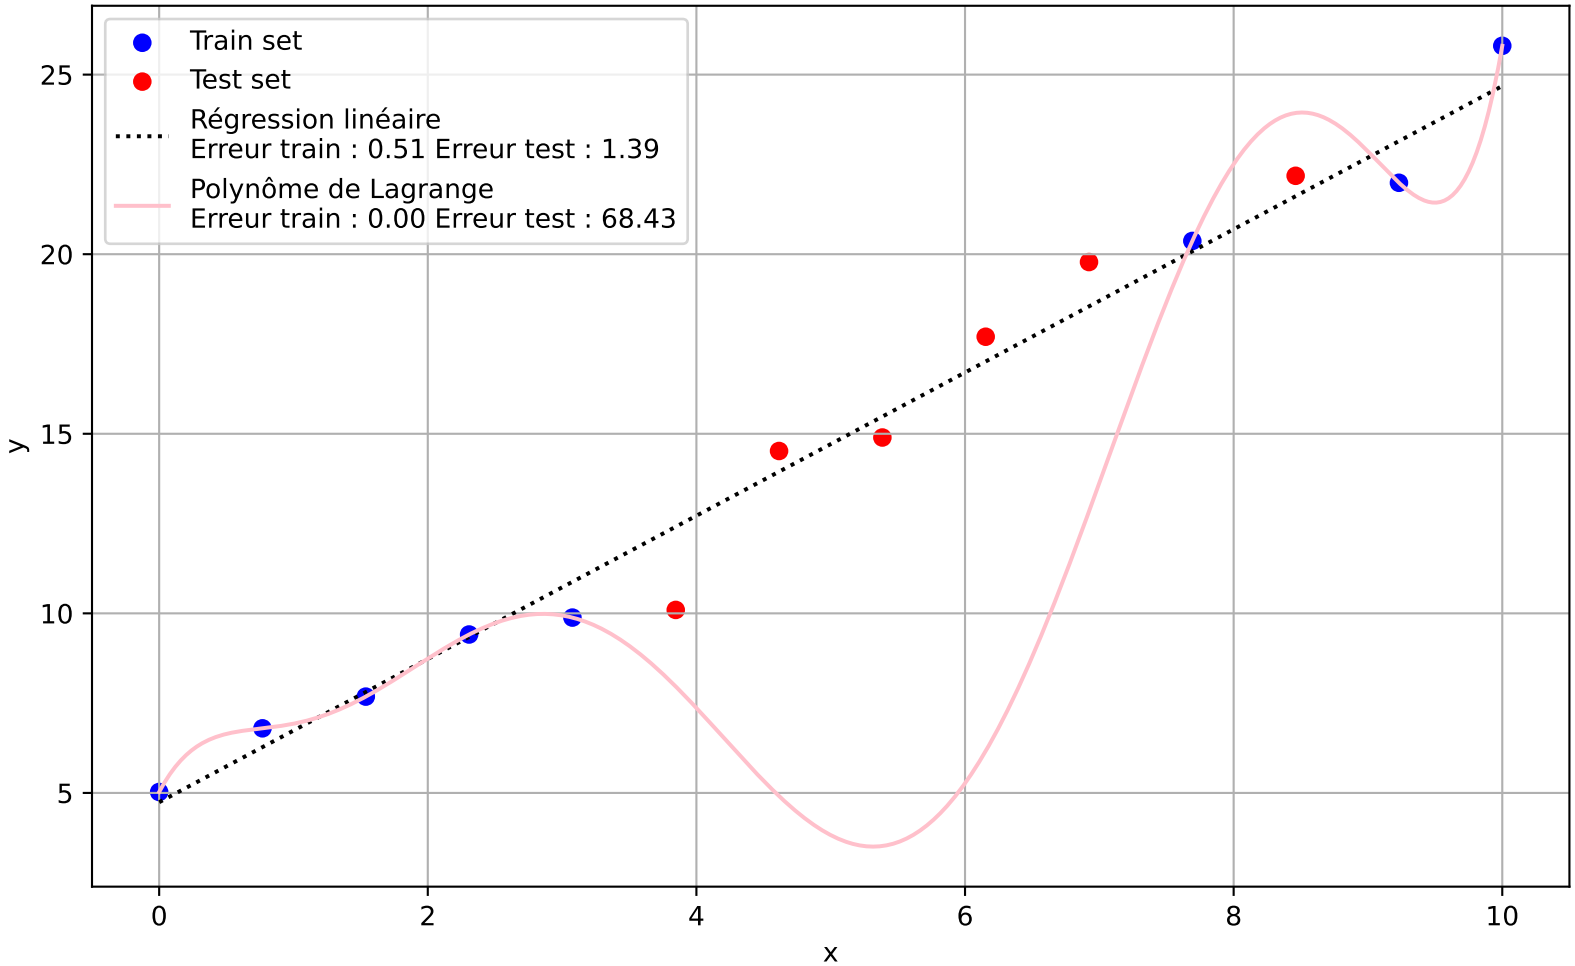

Mesurer l'overfitting : Test set

La différence entre la performance du modèle sur le jeu de **train** et le jeu de **test** est une mesure de l'overfitting. Plus cette différence est élevée plus l'overfitting est grand.

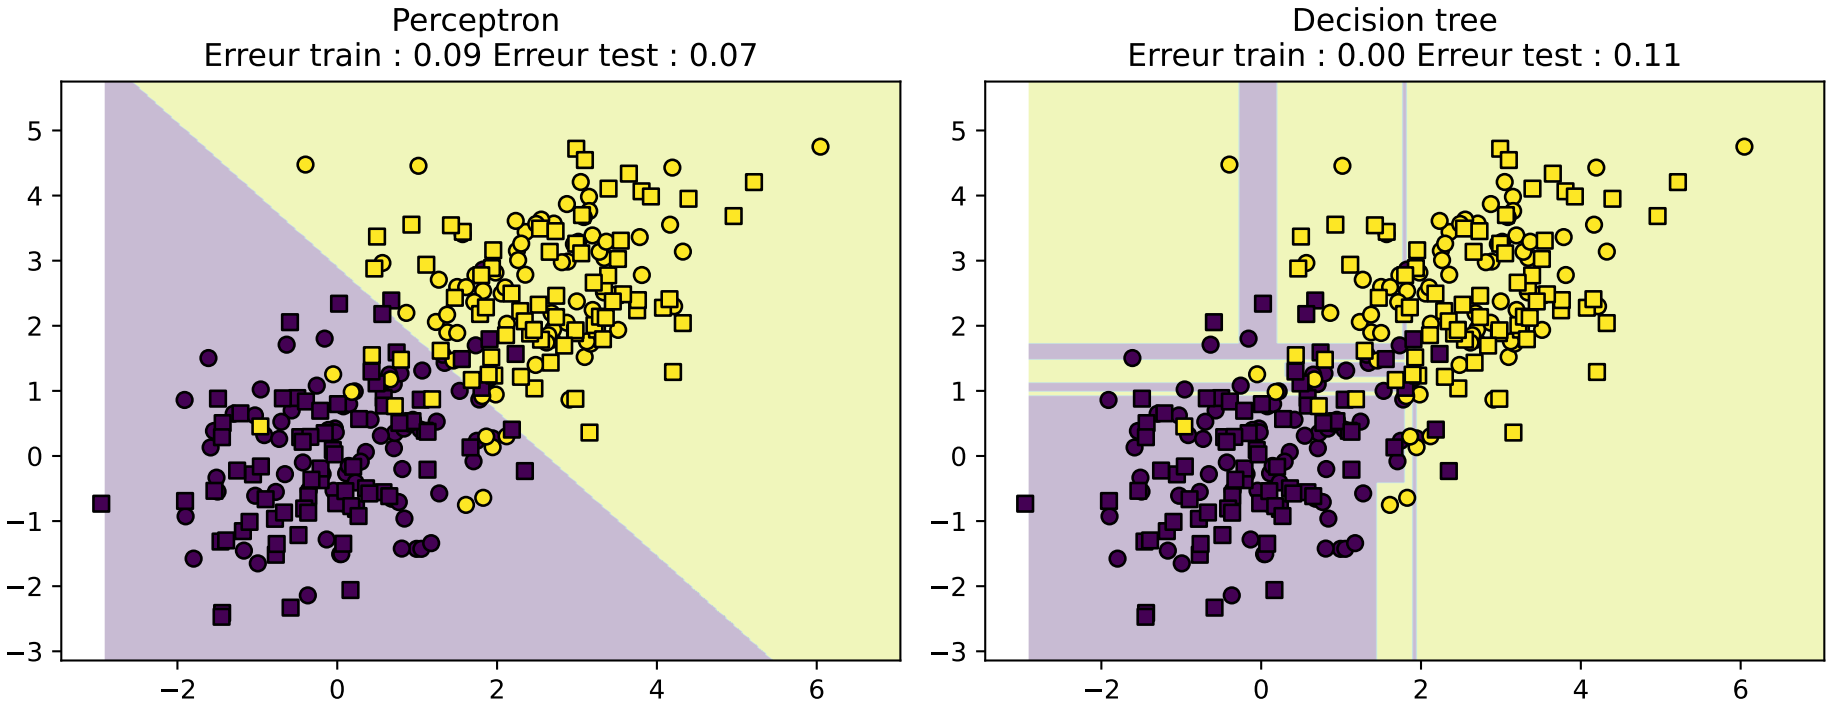

Overfitting et taille du dataset

Augmenter le nombre de données permet de limiter l'Overfitting en diminuant la **variance**. Intuition : avec peu de données, un modèle (surtout très complexe) peut facilement les mémoriser.

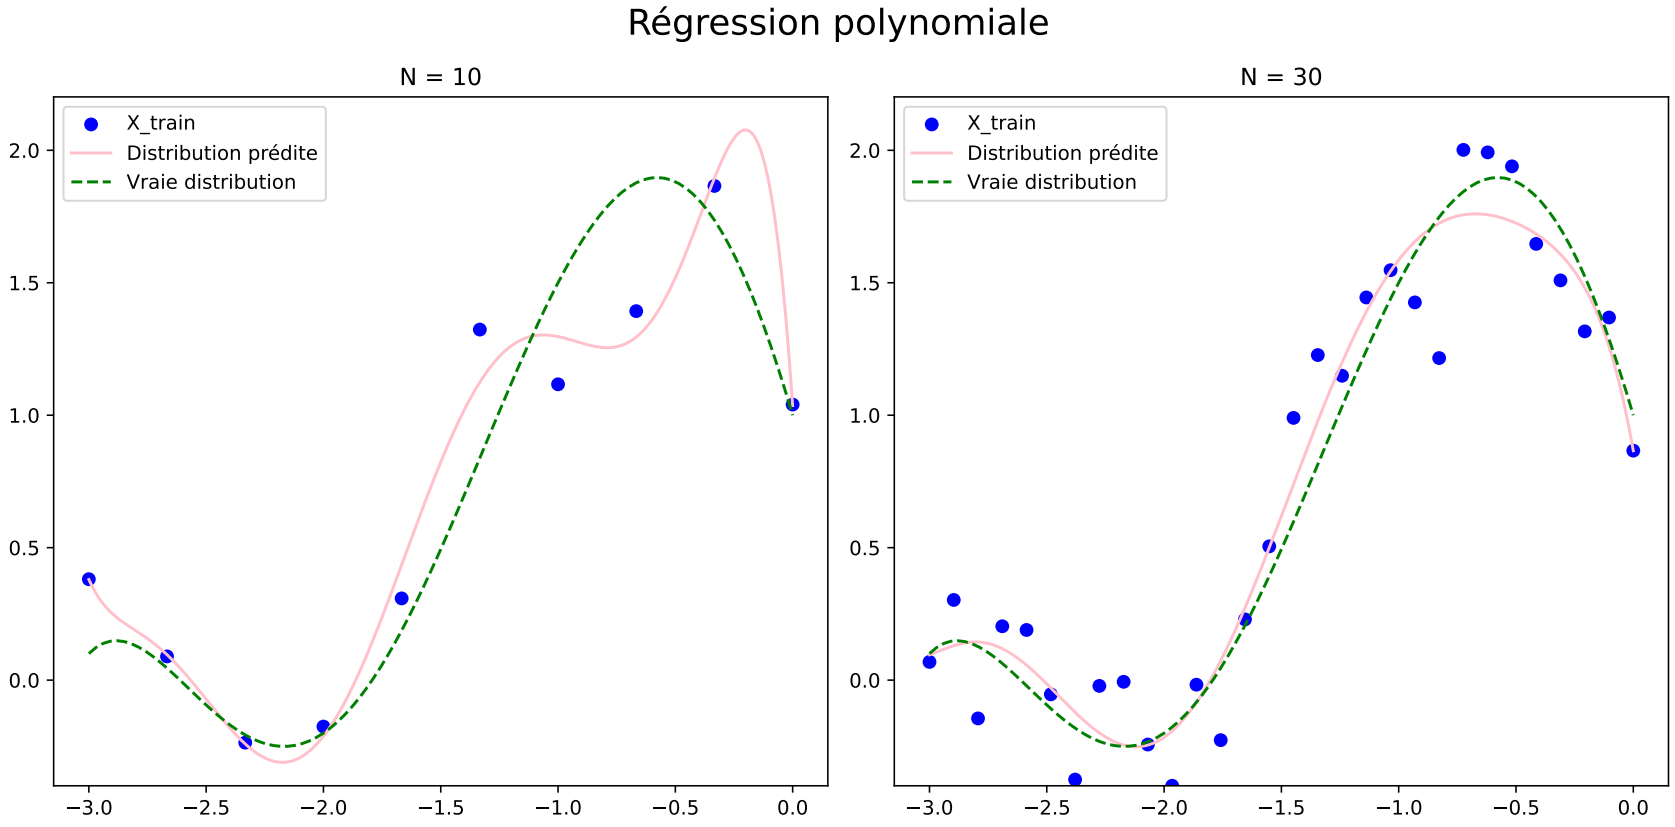

Overfitting et taille du dataset

Comment savoir si l'on over-fit à cause du manque de données ?
Learning curve.

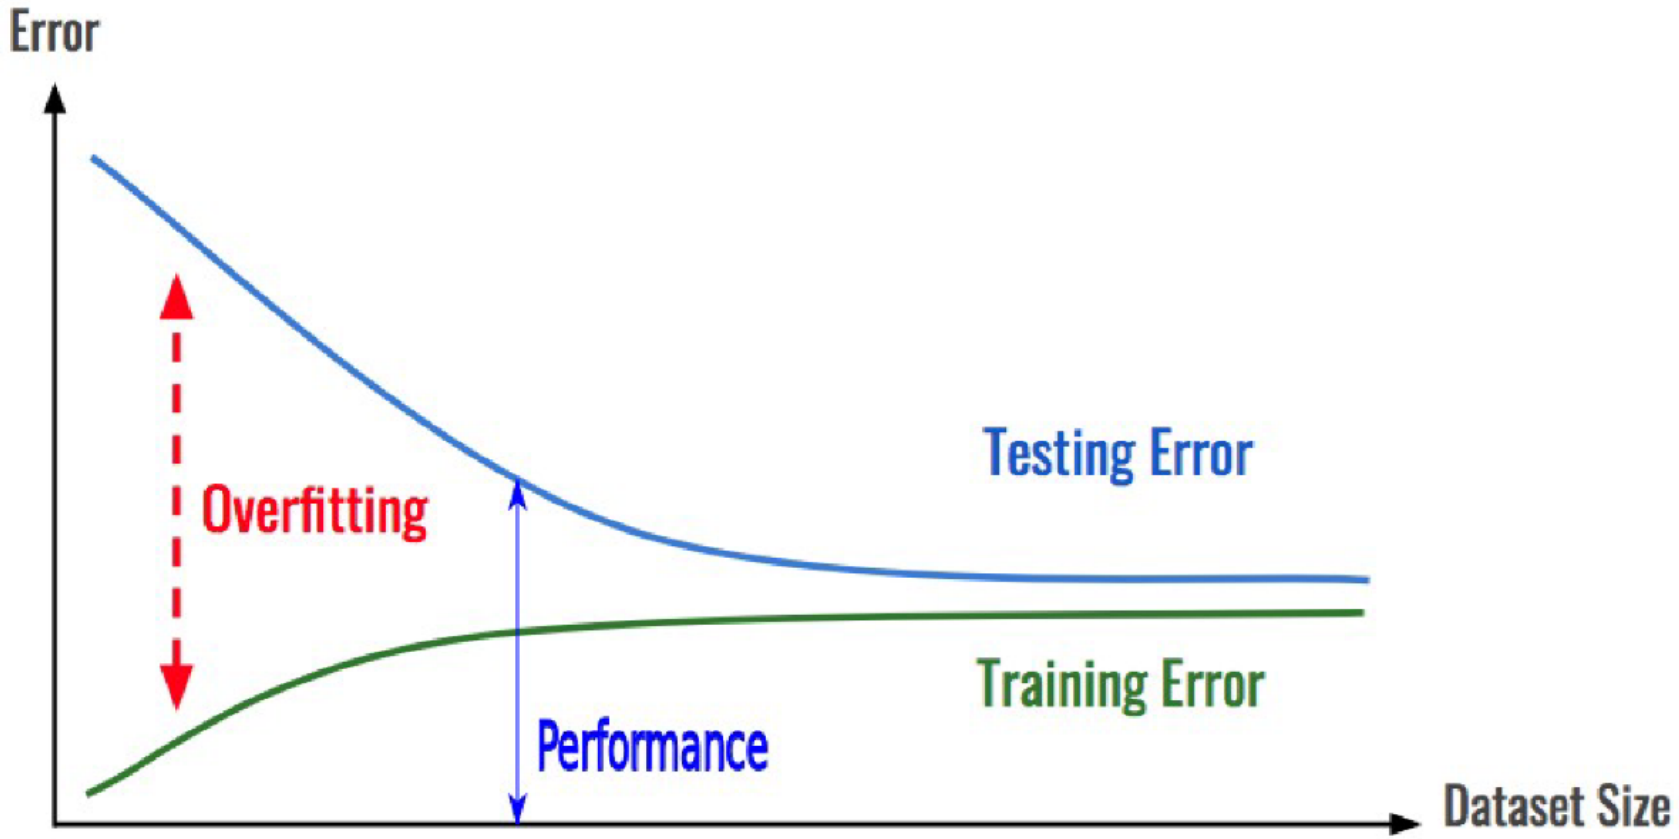

Overfitting et complexité du modèle

Augmenter la complexité d'un modèle peut améliorer ses performances en réduisant le **biais**, mais au-delà d'un certain seuil, cela peut entraîner de l'overfitting en augmentant la **variance**. Intuition : un modèle très complexe peut mémoriser les données d'entraînement ou apprendre le **bruit**.

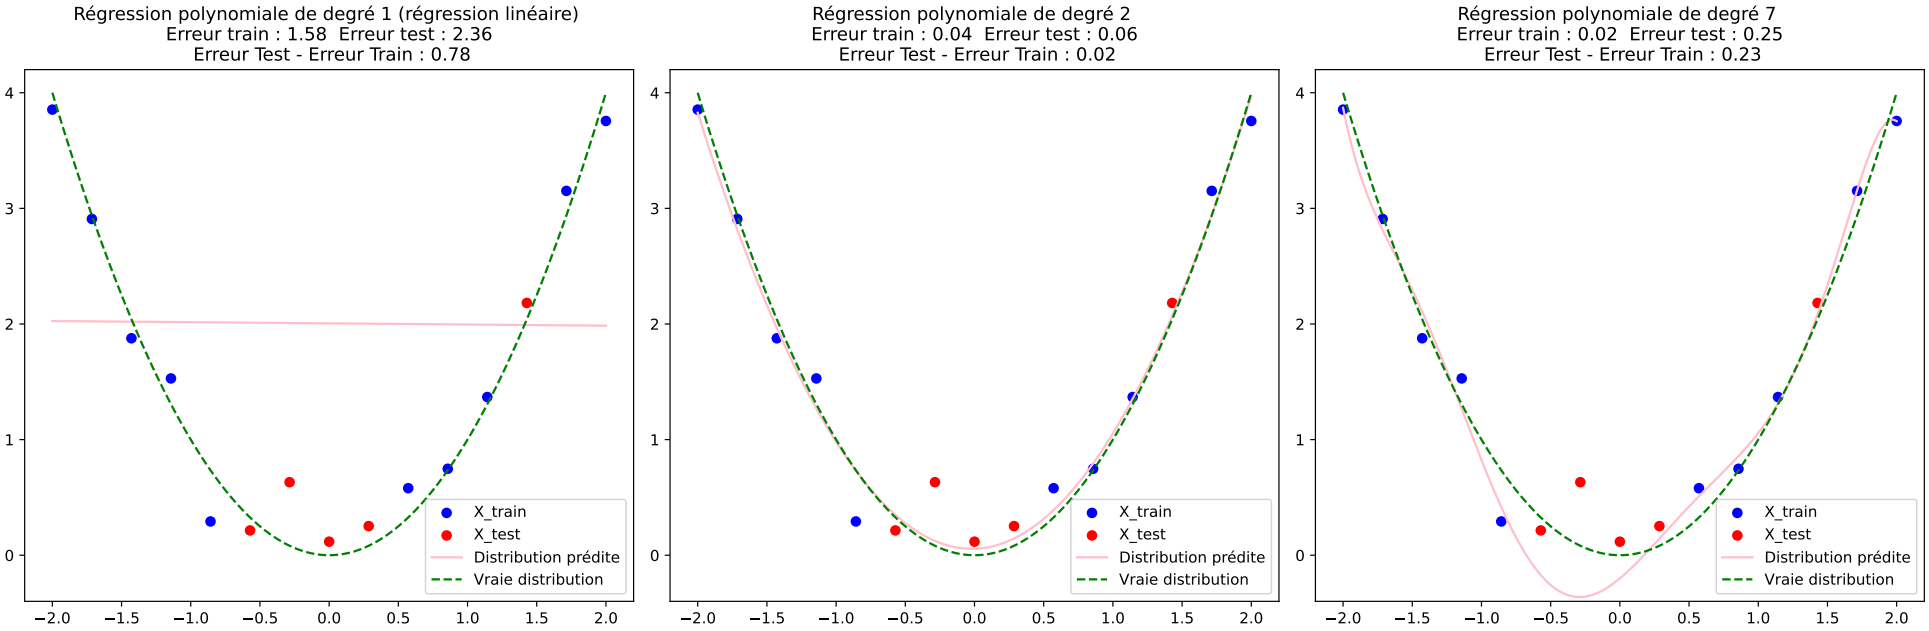

Overfitting et complexité du modèle

Comment savoir si la complexité du modèle est bonne ?
Learning curve.

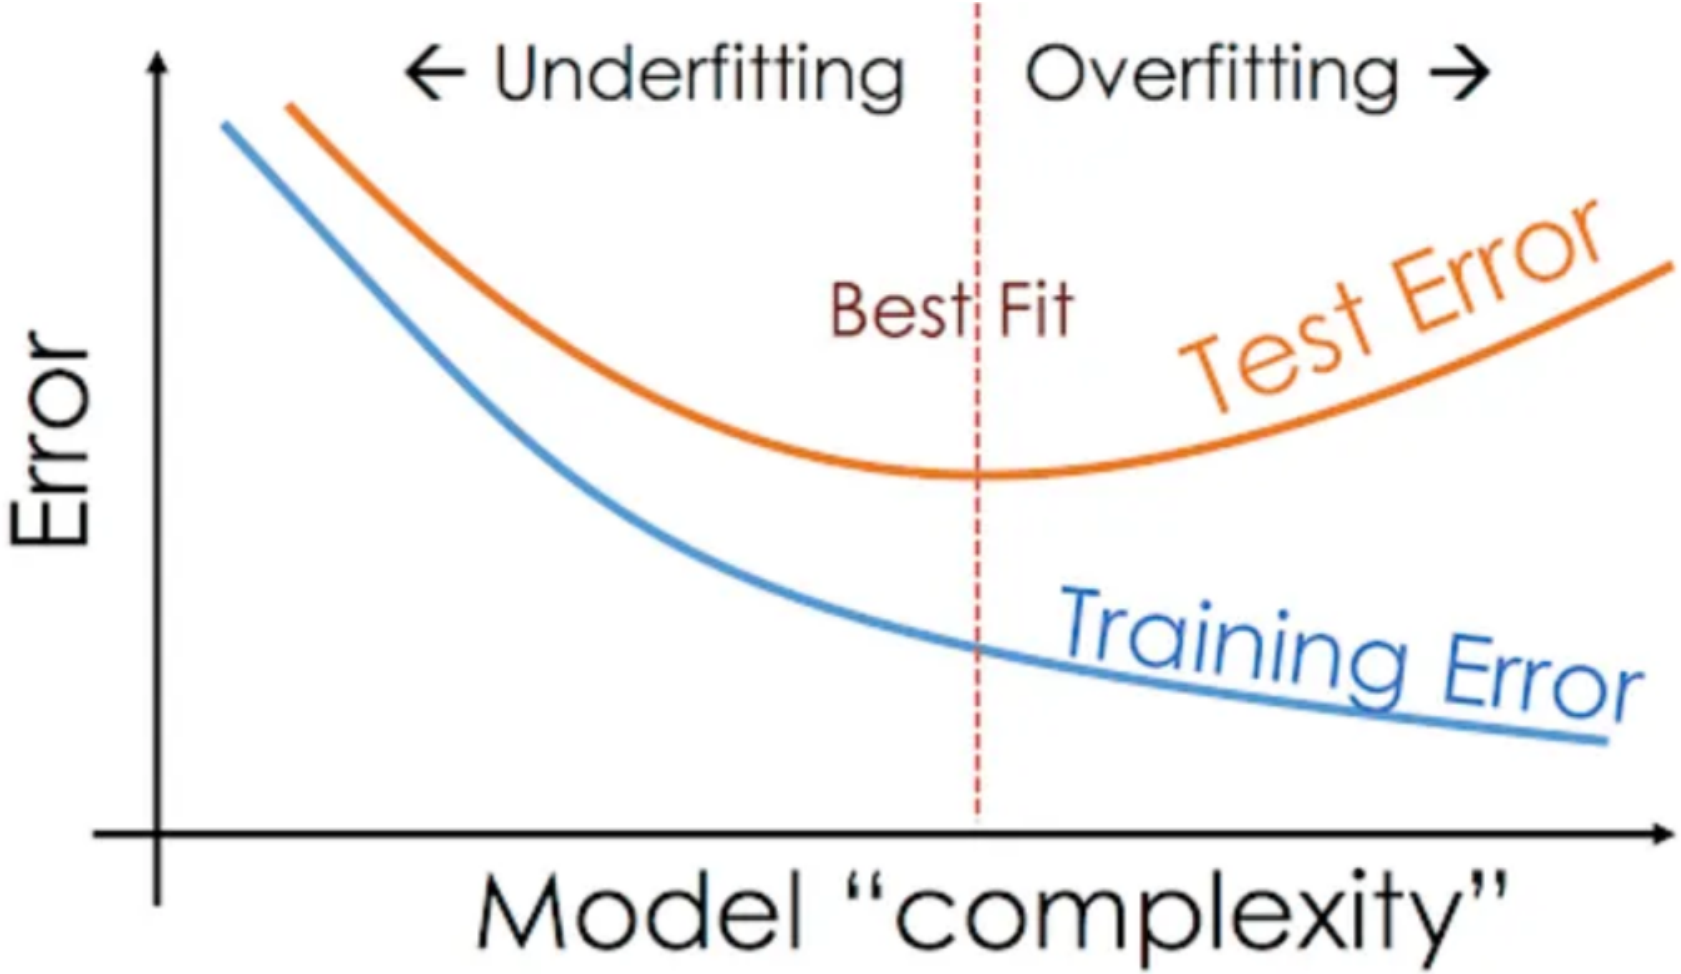

Overfitting et complexité du modèle

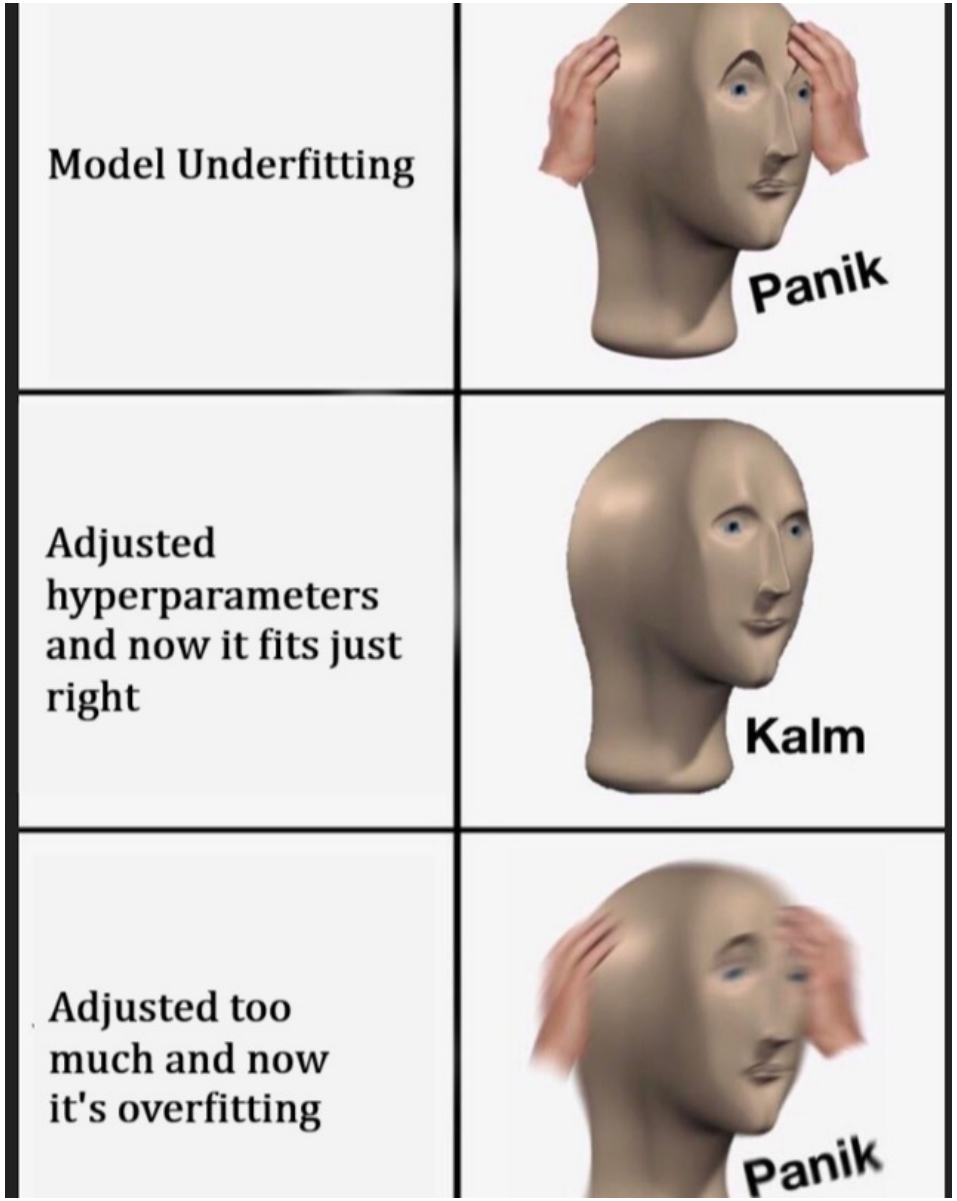

Hyper-paramètres

L'overfit (ou l'underfit) dépend de divers de choix : les hyper-paramètres, notés μ.

- Le choix du modèle (perceptron, SVM, decision tree...).
- La taille de l'ensemble d'entrainement (ici on veut toujours le max)
- Kernels (méthode d'ajout de features - prochain CM)
- Taux d'apprentissage η
- Initialisation des paramètres Θ_0
- Pre-processing (choix des données, features, normalisation...)
- Critère d'arrêt, pour les méthodes itératives
- etc.

Choix des hyperparamètres : Validation set

Comment choisir nos hyperparamètres ? On découpe nos données non pas en deux ensembles train et test, mais en trois : **train**, **validation** et **test**.

- Le **train set** sert à apprendre les paramètres de notre modèle, par exemple le vecteur w définissant l'hyperplan pour le perceptron.
- Le **validation set** sert à apprendre les hyperparamètres de notre modèle, par exemple la profondeur d'arbre max h_{max} pour les arbres de décision.
- Le **test set** ne s'utilise qu'**une seule fois** et sert à mesurer les performances finales de notre modèle. Pourquoi une seule fois ? Sinon on risque d'overfit sur nos hyperparamètres.