CM6 : Réduction dimensionnelle : Principal Components Analysis, PCA

1 Réduction des dimensions

Les features maps permettent d'augmenter les dimensions des données, nous allons maintenant voir la PCA, une technique permettant l'opération inverse, c'est à dire réduire la dimension des données. Dans quels intérêts ?

- Des intérêts directement liés au ML :
  - **Réduire le bruit** dans les données, c'est à dire les features inutiles à la prédiction. Cela permet de faciliter l'entrainement du modèle, mais aussi de **réduire sa variance**. En effet une cause de l'overfitting est l'apprentissage du bruit.
  - Supprimer des features redondantes (apportant une même information), cela réduit le coût, la durée de l'apprentissage.
  - En réduisant les dimensions, éviter la curse of dimensionality et donc réduire la variance (c'est à dire la capacité à overfit).
- Réduire la taille des données (algorithme de compression).
- En réduisant la taille des données à deux dimensions, la réduction des dimensions peut être utilisée pour la visualisation des données.

2 PCA : intuition

On souhaite trouver une fonction $\phi : \mathbb{R}^D \to \mathbb{R}^{D'}$ qui **projette** nos données de leur espace initial de dimension D a un espace (hyperplan) de dimension D' avec $D' < D$. Après application de la PCA, chaque dimension/nouvel attribut, sera une combinaison linéaire des attributs d'entrée. On notera en général $\vec{x}' = P\vec{x}$ les données après projection P étant la **matrice de projection** de dimension (D, D').

La question qui se pose maintenant est : comment choisir un bon hyper-plan sur lequel ou voudrait projeter ? Le choix fait, dans le cadre de la PCA, est de prendre l'hyperplan tel que **la variance des données, après projection, est maximale**. On favorise donc les dimensions de grande variance (et leurs combinaisons linéaires). Ce choix est équivalent à un autre choix, qui serait

celui de vouloir minimiser l'erreur de reconstruction (en norme L2, c'est-à-dire de minimiser l'erreur quadratique moyenne de reconstruction). L'idée (naïve) est donc de garder les attributs qui varient le plus (car se sont ceux qui portent le plus d'information).

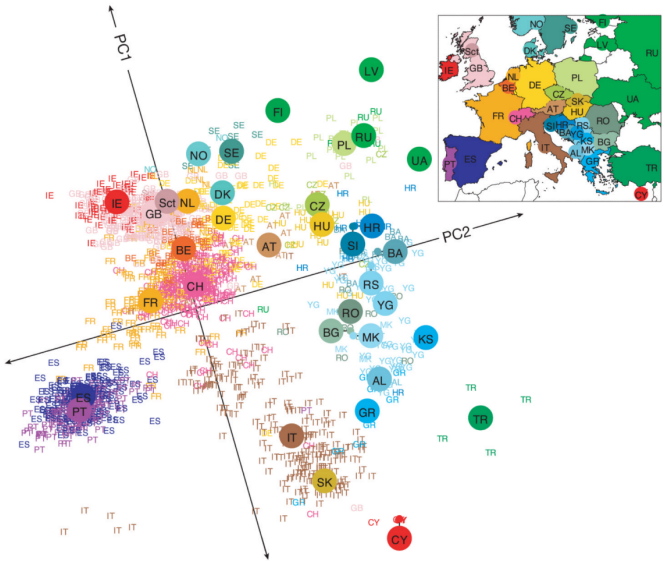

Figure 1: Visualisation de données génétiques par PCA, réduction de la dimension de 197146 à 2.

Note : La PCA est un algorithme **non supervisé**, il n'y a pas de labels associés à nos données. Par contre, la PCA peut être utilisée en preprocessing d'un algorithme de classification / régression supervisé.

3 PCA : démonstration

3.1 Variance des données après projection

On souhaite maximiser la variance des données après projection. Calculons donc la variance des données, après projection.

Projetons d'abord dans une seule direction donnée par un vecteur $\vec{u}_i$, le projeté de $\vec{x}_n$ est alors simplement le scalaire $\vec{u}_i.\vec{x}_n$. Nous souhaitons maximiser la variance des données après projection, cette variance est par définition donnée par :

$$\sigma_i^2 = \frac{1}{N}\sum_n^N (\vec{u}_i^T \vec{x}_n - \langle \vec{u}_i^T \vec{x} \rangle)^2$$

La notation $\langle \vec{x} \rangle$ désigne un vecteur de même dimension que $\vec{x}$ contenant la moyenne empirique de $\vec{x}$ c'est à dire $\langle \vec{x} \rangle = \frac{1}{N}\sum_n \vec{x}_n$.

Une autre remarque sur les notations, pour deux vecteurs $\vec{a}$ et $\vec{b}$ la notation $\vec{a}.\vec{b}$ est bien définie, c'est le produit scalaire, $\vec{a}.\vec{b} = \sum_i a_i.b_i$. Par contre si $\vec{a}$ est un vecteur de taille N et B est une matrice de taille (N, N), la notation $\vec{a}.B$ est ambigue, incorrecte, car ce n'est plus un produit scalaire, mais un produit matriciel. On écrira donc $\vec{a}^T.B$ pour que les dimensions est les notations soient cohérentes, mais dans le cas de deux simples vecteurs, on a bien $\vec{a}.\vec{b} = \vec{a}^T\vec{b}$.

Reprenons la preuve et montrons que :

$$\sigma_i^2 = \vec{u}_i^T.C.\vec{u}_i$$

Où C est la matrice de covariance de nos données, définie par :

$$C = \frac{1}{N}\sum_n^N (\vec{x}_n - \langle\vec{x}\rangle)(\vec{x}_n - \langle\vec{x}\rangle)^T$$

$$\begin{aligned}
\sigma_i^2 &= \frac{1}{N}\sum_n^N (\vec{u}_i^T\vec{x}_n - \langle\vec{u}_i^T\vec{x}\rangle)^2 && \text{Définition de la variance} \\
&= \frac{1}{N}\sum_n^N (\vec{u}_i^T\vec{x}_n - \langle\vec{u}_i^T\vec{x}\rangle).(\vec{u}_i^T\vec{x}_n - \langle\vec{u}_i^T\vec{x}\rangle)^T && \text{Un scalaire est bien égal à sa transposée} \\
& && \text{(simple manipulation pour obtenir ce que l'on souhaite)} \\
&= \frac{1}{N}\sum_n^N (\vec{u}_i^T.(\vec{x}_n - \langle\vec{x}\rangle).(\vec{u}_i^T.(\vec{x}_n - \langle\vec{x}\rangle)^T && \text{On peut vérifier facilement que } \langle\vec{u}_i^T.\vec{x}\rangle = \vec{u}_i^T.\langle\vec{x}\rangle \\
&= \frac{1}{N}\sum_n^N \vec{u}_i^T(\vec{x}_n - \langle\vec{x}\rangle).(\vec{x}_n - \langle\vec{x}\rangle)^T.\vec{u}_i && (A.B)^T = B^T.A^T \\
&= \vec{u}_i^T.(\frac{1}{N}\sum_n^N (\vec{x}_n - \langle\vec{x}\rangle).(\vec{x}_n - \langle\vec{x}\rangle)^T).\vec{u}_i \\
&= \vec{u}_i^T.C.\vec{u}_i
\end{aligned} \tag{1}$$

3.2 Maximisation de la variance après projection

Notre objectif est toujours de trouver $\vec{u}_i$ qui maximise la variance des données projetées, on cherche donc :

$$\arg\max_{\vec{u}_i}(u_i^T.C.u_i)$$

Le problème est qu'une solution facile pour maximiser cette valeur est de prendre $||\vec{u}_i||_2^2$ très grand, nous allons devoir contraindre ce vecteur à avoir une norme valant 1, c'est à dire $||\vec{u}_i||_2^2 = 1 = \vec{u}_i^T.\vec{u}_i$.

Pour cela, nous maximisons le Lagrangian :

$$\mathcal{L}(\vec{u}_i, \lambda) = (\vec{u}_i^T.C.\vec{u}_i) + \lambda(1 - \vec{u}_i^T.\vec{u}_i)$$

Vous pouvez admettre que maximiser le Lagrangian permet effectivement d'obenir ce que l'on souhaite, mais vous pouvez aussi facilement remarquer que la dérivée selon λ s'annule seulement au point $||\vec{u}_i||_2^2 = 1$.

Premièrement,

$$\begin{aligned}
\nabla_{\vec{u}_i}(\vec{u}_i^T.C.\vec{u}_i) &= \nabla_{\vec{u}_i}(\frac{1}{N}\sum_n^N(\vec{u}_i^T.(\vec{x}_n - \langle\vec{x}\rangle))^2) \\
&= \frac{1}{N}\sum_n^N 2.(\vec{x}_n - \langle\vec{x}\rangle).(\vec{u}_i^T.(\vec{x}_n - \langle\vec{x}\rangle)) \\
&= \frac{2}{N}\sum_n^N(\vec{x}_n - \langle\vec{x}\rangle).(\vec{x}_n - \langle\vec{x}\rangle)^T.\vec{u}_i \\
&= 2.C.\vec{u}_i
\end{aligned} \tag{2}$$

et,

$$\nabla_{\vec{u}_i}(\lambda(1 - \vec{u}_i^T.\vec{u}_i)) = 0 - 2.\lambda.\vec{u}_i \tag{3}$$

Ainsi,

$$\nabla_{\vec{u}_i}\mathcal{L}(\vec{u}_i, \lambda) = 2C\vec{u}_i - 2\lambda\vec{u}_i \tag{4}$$

On cherche le maximum, donc quand la dérivée du Lagrangian est nulle, c'est à dire,

$$C\vec{u}_i = \lambda\vec{u}_i \tag{5}$$

C'est l'équation aux valeurs propres, nous avons donc plusieurs extremums, tous sont des vecteurs propres, lequel choisir ?

Calculons la variance pour chacun :

$$\begin{aligned}
\sigma_i^2 &= (\vec{u}_i^T C\vec{u}_i) \\
&= (\vec{u}_i^T \lambda\vec{u}_i) \\
&= \lambda\vec{u}_i^T\vec{u}_i \\
&= \lambda
\end{aligned} \tag{6}$$

La projection qui maximise la variance est donc **selon la direction du vecteur propre avec la plus grande valeur propre**. La seconde direction, est le vecteur propre avec la deuxième plus grande valeur propre etc.

La conclusion est juste, mais un peu rapide, pourquoi est ce un maximum ? Pourquoi est ce que la seconde valeur propre est aussi un maximum ? Finissons la démonstration.

Soit un vecteur $\vec{u}$ quelconque de norme $||\vec{u}||_2^2 = 1$, calculons la variance des données sur ce vecteur. Puisque C est symétrique, les vecteurs propres de C forment une base orthogonale et on peut écrire $\vec{v} = \sum_i \alpha_i \vec{u}_i$ avec $\sum_i \alpha_i^2 = 1$. Le vecteur $\vec{u}_i$ étant le vecteur propre de norme 1 associé à la valeur propre λ_i.

Ainsi,

$$\vec{u}^T C \vec{u} = \sum_i \alpha_i \lambda_i \leq \lambda_1 = \vec{u}_1^T C \vec{u}_1$$

Pourquoi choisir ensuite de projeter sur le second vecteur propre ? Même raisonnement. Tout vecteur $\vec{u}$ de norme 1 est orthogonal au premier vecteur propre $\vec{u_1}$ peut s'écrire :

$\vec{u} = \sum_{i=2} \alpha_i \vec{u}_i$ avec $\sum_{i=2} \alpha_i^2 = 1$.

Ainsi,

$\vec{u}^T C \vec{u} = \sum_{i=2} a_i^2 \lambda_i \leq \lambda_2 = \vec{u}_2^T C \vec{u}_2$

Le maximum est donc atteint pour le second vecteur propre associé à la seconde valeur propre.

Si l'on souhaite maximiser la variance de la projection des données sur un sous-espace de dimension D', il faut donc projeter les données sur le sous-espace engendré par les D' vecteurs propres associés aux D' plus grandes valeurs propres de la matrice de covariance de nos données. Notre matrice de projection est donc $P = (\vec{u_1}\vec{u_2}...\vec{u_{D'}})$.

Nos données projetées $\vec{x}_{n,compressed}$, après PCA sont données :

$$\vec{x}_{n,compressed} = P^T(\vec{x}_n - \langle \vec{x} \rangle)$$

Pour reconstruire nos données :

$$\vec{x}_{n,decompressed} = P\vec{x}_{n,compressed} + \langle \vec{x} \rangle$$

3.3 Résumé de l'algorithme de PCA

Nous souhaitons projeter nos données d'un espace de dimension D, dans un espace vectoriel de dimension $D' < D$. L'idée de la PCA est de choisir la projection qui maximise la variance des données après projection ou de manière équivalente, minimise l'erreur de reconstruction. Nous venons de démontrer que l'espace vectoriel D' satisfaisant cette propriété est l'espace généré par les D' vecteurs propres associées aux D' plus grande valeurs propres de la matrice de covariance des données. L'algorithme est donc le suivant :

- Calculer la matrice de covariance $C = \frac{1}{N}\sum_n^N (\vec{x}_n - \langle \vec{x} \rangle)(\vec{x}_n - \langle \vec{x} \rangle)^T$. Compléxité $O(ND^2)$.
- Calculer les vecteurs propres de C. Compléxité $O(D^3)$, sauf si l'on chercher seulement les k premiers vecteurs propres, alors $O(kD^2)$.

- $P = (\vec{u}_1 \vec{u}_2 ... \vec{u}_{D'})$ les D' vecteurs propres associés aux D' plus grandes valeurs propres, calculer la projection des données : $\vec{x}_{n,decompressed} = P\vec{x}_{n,compressed} + \langle \vec{x} \rangle$