CM8&9 : Modèles Bayésiens

Une manière fondamentale de comprendre le machine learning est de supposer que les données sont générées par une loi de probabilité $P(X, Y)$, inconnue, inaccessible directement, et souvent très complexe. On n'en dispose que d'un échantillon fini : le jeu d'entraînement. La tâche est alors de reconstruire, d'estimer toute ou une partie de cette loi à partir de cet échantillon. En apprentissage supervisé, on cherche à estimer $P(Y|X)$, la distribution de target Y sachant l'entrée X.

1 Classifieur bayésien optimal

Imaginions que nous connaissions exactement $P(Y|X)$ (ce n'est presque jamais le cas en pratique), alors nous pourrions pour une donnée $\vec{x}$ simplement prédire son label le plus probable :

$$\text{Prédiction du classifieur bayésien optimal : } y^* = h_{opt}(\vec{x}) = \underset{y}{\operatorname{argmax}}\, P(y|\vec{x})$$

Même si ce modèle est le meilleur possible, cela ne signifie pas qu'il ne peut pas se tromper. Il est possible que pour une donnée, sa classe ne soit pas la classe la plus probable. Le taux d'erreur est précisément :

$$\epsilon_{opt} = 1 - P(y^*|\vec{x}) = 1 - P(h_{opt}(\vec{x})|\vec{x})$$

Imaginez par exemple que l'on souhaite déterminer la réussite d'un élève au bac (classification binaire) en fonction de sa moyenne générale pendant l'année. On peut imaginer, en notant (+1) réussite au bac et (-1) échec, que :

$$P(+1|7) = 0.3$$
$$P(-1|7) = 0.7$$

La meilleur prédiction pour un élève ayant eu 7 de moyenne pendant l'année est "échec", **il est impossible de faire une meilleure prédiction**, mais il restera toujours un taux d'erreur de 0.3. Cela illustre parfaitement la notion de **bruit** que nous avions vu pendant le cours sur l'overfitting, le bruit est ce taux d'erreur intrinsèque à la nature des donnée en dessous duquel on ne peut aller, quelque soit le choix modèle.

Le classifieur bayésien optimal est le meilleur modèle possible, mais il demande de connaitre précisement $P(Y|X)$, ce qui est en pratique presque toujours impossible. L'idée de la **classification naïve bayésienne** est d'estimer cette loi de probabilité via la formule de Bayes :

$$P(Y|X) = \frac{P(X|Y)P(Y)}{P(X)}$$

On va donc estimer $P(X|Y)$ et $P(Y)$ (on verra que $P(X)$ n'a pas besoin d'être estimé) pour ensuite effectuer la prédiction grâce à cette formule.

Notez que **tous les modèles (supervisés) essayent d'estimer** $P(Y|X)$, ce n'est en aucun cas une spécifité de la classification naïve bayésienne, mais c'est peut être ici qu'on le voit le plus directement et pour cela que nous présentons le machine learning ainsi dans cette séance.

2 Maximum Likelihood Estimation (MLE)

Lorsqu'on souhaite trouver la loi de probabilité P modélisant au mieux un ensemble de données $\mathcal{D} = (x_1, x_2, ...x_N)$, la méthode naturelle consiste à supposer que $\mathcal{D}$ provient d'une loi de probabilité ayant pour paramètres θ que l'on va chercher à estimer. On va définir et noter $\mathcal{L}(\theta) = P(\mathcal{D}; \theta)$ la **fonction de vraisemblance** (likelihood), c'est elle qu'on cherche à maximiser. En supposant les données indépendantes et identiquement distribuées (i.i.d.), on a:

$$\mathcal{L}(\theta) = P(\mathcal{D}; \theta) = \prod_{n=1}^{N} P(x_n; \theta)$$

Cette approche s'appelle l'estimation par le maximum de vraisemblance (des données). On cherche à trouver les paramètres optimaux θ^* qui maximisent :

$$\theta^* = \underset{\theta}{\operatorname{argmax}}\, \mathcal{L}(\theta)$$

2.1 MLE avec une variable

Prenons un exemple concret, par exemple la taille en cm d'un certain nombre N d'étudiants. On dispose de N points de données, à une dimension, c.a.d que ce sont des nombres réels. On suppose que **les tirages sont indépendants**. On souhaite trouver la loi de probabilité P modélisant au mieux nos données. La première étape est de savoir quel modèle mathématique nous allons utiliser pour cela. Cette étape est un choix de modélisation pour lequel il n'y a pas de méthode automatique, il faut décider en fonction de nos données. Pour la taille, nous allons choisir une gaussienne.

La fonction de densité d'une gaussienne est :

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$$

Où $\theta = (\mu, \sigma)$ sont les paramètres de la gaussienne, c'est donc exactement ces paramètres que l'on cherche à estimer grâce au MLE.

On cherche donc toujours,

$$\theta^* = \underset{\theta}{\operatorname{argmax}}\, \mathcal{L}(\theta)$$

Cependant, on va plutôt chercher, de façon parfaitement équivalente :

$$\theta^* = \underset{\theta}{\operatorname{argmax}} \log \mathcal{L}(\theta)$$

On notera $l(\theta) = \log \mathcal{L}(\theta)$ la fonction de **log-likelihood**.

Pourquoi ce passage au log ? Pour deux raisons, la première, mathématique, va apparaitre clairement dans les prochaines équations, le passage au log permet de grandement simplifier les calculs. La seconde, informatique, est qu'un ordinateur est incapable de gérer de trop petits ou grands nombres, sa précision devient très faible et ses bornes limites peuvent être rapidement dépassées. Il est alors primordial de calculer le log des probabilités et non les probabilités elles même.

Reprenons notre estimation de θ :

$$\begin{aligned}
\theta^* &= \underset{\theta}{\operatorname{argmax}} \log \mathcal{L}(\theta) && (1)\\
&= \underset{\theta}{\operatorname{argmax}} \log \prod_{n=1}^{N} P(x_n;\theta) && (2)\\
&= \underset{\theta}{\operatorname{argmax}} \sum_{n=1}^{N} \log P(x_n;\theta) && (3)\\
&= \underset{\theta}{\operatorname{argmax}} \sum_{n=1}^{N} \log \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(x_n-\mu)^2}{2\sigma^2}\right) && (4)\\
&= \underset{\theta}{\operatorname{argmax}} \sum_{n=1}^{N} \log \frac{1}{\sigma\sqrt{2\pi}} + \sum_{n=1}^{N} \log \exp\left(-\frac{(x_n-\mu)^2}{2\sigma^2}\right) && (5)\\
&= \underset{\theta}{\operatorname{argmax}} -N\log(\sigma\sqrt{2\pi}) - \sum_{n=1}^{N} \frac{(x_n-\mu)^2}{2\sigma^2} && (6)\\
&= \underset{\theta}{\operatorname{argmin}} N\log(\sigma\sqrt{2\pi}) + \sum_{n=1}^{N} \frac{(x_n-\mu)^2}{2\sigma^2} && (7)
\end{aligned}$$

Détail des étapes : (1) définition, (2) définition, (3) $\log(a\cdot b) = \log(a)+\log(b)$, (4) passe à la fonction de densité, (5) $\log(a\cdot b) = \log(a)+\log(b)$, (6) $\sum^N a = Na$

et $\log(\exp(a)) = a$, (7) $\text{argmax}_x -f(x) = \text{argmin}_x f(x)$.

Comment trouver le mininum d'une fonction concave ? C'est le point où sa dérivée s'annule (et où sa dérivée seconde est positive, sinon c'est un maximum). Nous allons donc dériver l'expression selon μ et σ pour trouver $\theta^* = (\mu^*, \sigma^*)$:

$$\begin{aligned}
\frac{\partial - \log \mathcal{L}(\theta)}{\partial \mu} &= \frac{\partial N \log(\sigma\sqrt{2\pi})}{\partial \mu} + \frac{\partial \sum_{n=1}^{N} \frac{(x_n-\mu)^2}{2\sigma^2}}{\partial \mu} \\
&= 0 + \sum_{n=1}^{N} \frac{-2(x_n - \mu)}{2\sigma^2} \\
&= \sum_{n=1}^{N} \frac{(\mu - x_n)}{\sigma^2}
\end{aligned}$$

On cherche le point μ^* où la dérivée s'annule :

$$\begin{aligned}
&\sum_{n=1}^{N} \frac{(\mu^* - x_n)}{\sigma^2} = 0 \\
&\iff \sum_{n=1}^{N} \mu^* = \sum_{n=1}^{N} x_n \\
&\iff N\mu^* = \sum_{n=1}^{N} x_n \\
&\iff \mu^* = \frac{1}{N} \sum_{n=1}^{N} x_n \\
&\iff \mu^* = \langle x \rangle
\end{aligned}$$

On vient donc de prouver que la meilleure estimation pour la moyenne μ de la gaussienne modélisant nos données est la moyenne empirique de nos données, c'est au moins cohérent.

On fait maintenant la même chose pour σ :

$$\begin{aligned}
\frac{\partial - \log \mathcal{L}(\theta)}{\partial \sigma} &= \frac{\partial N \log(\sigma\sqrt{2\pi})}{\partial \sigma} + \frac{\partial \sum_{n=1}^{N} \frac{(x_n-\mu)^2}{2\sigma^2}}{\partial \sigma} \\
&= \frac{N\sqrt{2\pi}}{\sigma\sqrt{2\pi}} + \sum_{n=1}^{N} -2\frac{(x_n - \mu)^2}{2\sigma^3} \\
&= \frac{N}{\sigma} - \sum_{n=1}^{N} \frac{(x_n - \mu)^2}{\sigma^3}
\end{aligned}$$

On cherche le point σ^* où la dérivée s'annule :

$$\begin{aligned}
&\frac{N}{\sigma^*} - \sum_{n=1}^{N} \frac{(x_n - \mu)^2}{{\sigma^*}^3} = 0 \\
&\iff N = \sum_{n=1}^{N} \frac{(x_n - \mu)^2}{{\sigma^*}^2} \\
&\iff {\sigma^*}^2 = \frac{1}{N} \sum_{n=1}^{N} (x_n - \mu)^2 \\
&\iff \sigma^* = \sqrt{\frac{1}{N} \sum_{n=1}^{N} (x_n - \mu)^2}
\end{aligned}$$

On trouve ici encore que le meilleur estimateur du paramètre σ pour modéliser les données, σ^* est égal à l'écart-type empirique.

Finalement, on retrouve les estimations fréquentistes, c.a.d que l'estimation du maximum de vraisemblance coïncide avec les estimations empiriques, mais la méthode est très générale !

3 Modèle Bayésien Naïf

Reprenons notre exemple de prédiction de la réussite au bac en fonction de la moyenne générale pendant l'année, imaginons les notes au demi-point prêt (entre 0 et 20), il y a ainsi une unique feature et 41 valeurs possibles pour cette feature. On peut assez facilement supposer que nous avons dans notre jeu d'entrainement de nombreux élèves pour chaque note. Il est alors possible d'estimer directement $P(Y|X)$ ainsi :

$$P(Y = +1|X = x) = \frac{P(X = x, Y = +1)}{P(X = x)} = \frac{|\{i : (x_i, y_i) = (x, +1)\}|}{|\{i : x_i = x\}|}$$

En d'autres termes, on estime la probabilité qu'un élève obtienne son bac en ayant eu la moyenne x par la proportion d'élèves dans nos données avec la moyenne x qui ont obtenu leur bac.

Si notre jeu d'entrainement n'est pas trop petit, c'est effectivement un bon modèle. Pourquoi ne pas toujours faire ça ? En règle général nos données ont plusieurs dimensions et chaque dimension peut prendre plusieurs valeurs, il est alors impossible d'avoir dans notre jeu d'entrainement des données correspondant à chaque combinaison de features possible. Par exemple si nous passons dans notre exemple à 6 features en prenant non plus la moyenne générale, mais la moyenne pour chaque élève dans 6 matières différentes, on obtient 5 milliards de combinaisons de notes différentes, difficile d'utiliser notre modèle précédent.

Puisque estimer $P(Y|X)$ directement est impossible dès que l'espace des features est grand, on va changer de point de vue. Par la **formule de Bayes** :

$$P(Y|X) \propto P(X|Y)P(Y)$$

On remplace un problème difficile ($P(Y|X)$ sur un grand espace) par deux problèmes plus simples : estimer $P(Y)$ (la proportion de réussite au bac globale) et $P(X|Y)$ (la distribution des notes chez les reçus, et chez les recalés). Ces deux quantités sont bien plus faciles à estimer depuis les données.

Cependant $P(X|Y)$ reste difficile dès que X est multidimensionnel - c'est ici qu'intervient l'**hypothèse "naïve"** : **on suppose les features indépendantes** conditionnellement à Y, ce qui permet d'écrire $P(X|Y) = \prod_d P(X_d|Y)$.

En notant h sa fonction de prédiction, l'algorithme bayésien naïf fonctionne donc ainsi :

$$\begin{aligned}
h(x) &= \operatorname*{argmax}_y P(y \mid x) && (8)\\
&= \operatorname*{argmax}_y \frac{P(x \mid y)P(y)}{P(x)} && (9)\\
&= \operatorname*{argmax}_y P(x \mid y)P(y) && (10)\\
&= \operatorname*{argmax}_y \prod_d^D P(x_d \mid y)P(y) && (11)\\
&= \operatorname*{argmax}_y \sum_d^D \log(P(x_d \mid y)) + \log(P(y)) && (12)
\end{aligned}$$

L'étape (10) vient du fait que $P(x)$ ne dépende pas de y et (11) n'est possible que grâce à l'hypothèse naïve .

3.1 Estimer $P(Y)$

La formule de Bayes nous demande d'estimer $P(X|Y)$ et $P(Y)$, commençons pas le second qui est assez simple. Soit c une classe, on va estimer que la probabilité de cette classe est simplement sa proportion dans notre jeu d'entrainement :

$$P(Y = c) = \frac{|\{i : y_i = c\}|}{N}$$

Par exemple si dans nos données d'entrainement 90% des élèves obtiennent leur bac, alors $P(Y = +1) = 0.9$ (et $P(Y = -1) = 0.1$).

3.2 Estimer $P(X \mid Y)$

Grâce à l'hypothèse naïve nous allons avoir seulement à estimer $P(X_d \mid Y)$ pour chaque dimension d de nos features. Suivant la nature de la dimension d (valeurs

continues ou valeurs discrètes) la fonction de probabilité que nous allons utiliser pour modéliser X_d va différer. Pour des valeurs continues on peut par exemple utiliser une loi gaussienne, pour des valeurs discrètes une loi de Bernoulli ou multinomiale. Dans tous les cas il faut ensuite estimer les paramètres de la loi à partir des données, par exemple grâce au MLE.

Pour reprendre notre exemple de notes aux bacs, avec 6 moyennes par élèves, une par matière, nous pouvons raisonnablement décider de modéliser la répartition des notes pour chaque matière $P(X_d \mid Y)$ par une loi gaussienne. Il y a 2 classes et 6 dimensions, il faut donc estimer les paramètres pour 12 gaussiennes.

3.3 Fonction de prédiction

Afin d'effectuer une prédiction pour une donnée x, reprenons la fonction de prédiction déjà définie en (8)-(12) :

$$h(x) = \underset{y}{\operatorname{argmax}}\, P(y \mid x) = \underset{y}{\operatorname{argmax}} \sum_{d}^{D} \log(P(x_d \mid y)) + \log(P(y))$$

Maintenant que nous connaissons $P(Y)$ et $P(X \mid Y)$, c'est une simple affaire de calcul. On calcule la quantité ci dessus pour chaque valeur possible y de Y. La valeur de y pour laquelle cette équation est maximale est par définition de h notre prédiction pour x.

4 Maximum A Posteriori (MAP)

Imaginons maintenant que nous trouvions une vieille pièce de monnaie légèrement déformée par le temps. Naturellement, nous nous demandons immédiatement quelle est la probabilité que cette pièce tombe sur face après l'avoir lancée en l'air. Pour cela nous décidons de la lancer N fois et de noter les résultats. Après 10 essais nous trouvons 8 faces et 2 piles. Nous décidons de modéliser le lancer de pièce par une **loi de Bernoulli** et en appliquant le MLE, nous trouvons sans grande surprise le paramètre de la loi $p = \frac{8}{10} = 0.8$ [1]. Il y a 8 chances sur 10 que la pièce tombe sur face.

Ceci calculé nous sommes un peu surpris du résultat, même si la pièce est légèrement déformée, nous nous attendions **a priori** à ce que la probabilité de face soit proche de 0.5. Que serait il arrivé si nous n'avions obtenu que des faces ? Aurions nous du conclure que la probabilité de pile est 0 ? Dans le cas présent nous pouvons répéter l'expérience plus de fois pour affiner notre

[1] Exercice : prouver ce résultat. On rappelle qu'une loi de Bernoulli est à valeur dans $\{0, 1\}$ et peut s'écrire de deux façons équivalentes :

$$P(X = k) = \begin{cases} p & \text{si } k = 1, \\ 1 - p & \text{si } k = 0. \end{cases} \text{ ou } P(X = k) = p^k (1 - p)^{1-k}$$

estimation, mais ce n'est que rarement possible dans des cas pratiques où les données sont limitées en nombre. Une méthode pour faire face à ce problème est le maximum a posteriori (MAP), l'idée est la même que pour MLE, mais on considère en plus que les paramètres de la distribution cherchée peuvent être modélisés eux même par une distribution de probabilité. Cette distribution modélise nos a priori sur les paramètres, avant même d'observer les données.

La formule de MAP est donc :

$$P(\theta|\mathcal{D}) = P(\mathcal{D}|\theta)P(\theta) = \prod_{n=1}^{N} P(x_n|\theta)P(\theta)$$

Où $P(\theta)$ est le prior sur les paramètres de la distribution. Pour reprendre notre exemple de la pièce, nous pensions a priori que la probabilité de face devait se situer autour de 0.5. Une bonne loi de probabilité pour modéliser ce prior (nous l'admettrons) est la loi beta avec pour paramètres $\alpha = \beta$, cette loi a pour fonction de densité $f(x) \propto x^{\alpha-1}(1-x)^{\beta-1}$. Choisissons $\alpha = 3$ (c'est un choix de modélisation) et calculons maintenant le MAP pour notre exemple avec 10 lancés, dont 8 faces :

$$\begin{aligned}
\theta^* &= \operatorname*{argmax}_{\theta} P(\theta|\mathcal{D}) && (13)\\
&= \operatorname*{argmax}_{\theta} \sum_{n=1}^{N} \log P(x_n|\theta) + \log P(\theta) && (14)\\
&= \operatorname*{argmax}_{\theta} 8\log(p) + 2\log(1-p) + \log(p^2(1-p)^2) && (15)\\
&= \operatorname*{argmax}_{\theta} 8\log(p) + 2\log(1-p) + 2\log(p) + 2\log(1-p) && (16)\\
&= \operatorname*{argmax}_{\theta} 10\log(p) + 4\log(1-p) && (17)
\end{aligned}$$

(14) application de la formule de MAP (15) 8 observations face (probabilité p chacune) et 2 observations pile (probabilité $(1-p)$ chacune), pour calculer $P(\theta)$ on a appliqué la fonction de densité de la loi beta.

On calcule la dérivée :

$$\frac{\partial \log \mathcal{L}(\theta)}{\partial p} = \frac{10}{p} - \frac{4}{1-p}$$

On cherche le point p où la dérivée s'annule :

$$
\begin{aligned}
&\frac{10}{p} - \frac{4}{1-p} = 0 \\
&\iff \frac{10}{p} = \frac{4}{1-p} \\
&\iff 10(1-p) = 4p \\
&\iff p = \frac{10}{14} \approx 0.7
\end{aligned}
$$

Nous voyons que notre nouvelle estimation de p est plus proche de 0.5 (notre prior) que précédemment, mais reste influencé par nos données. De plus, on peut vérifier que plus des données sont ajoutés, moins le prior a d'influence dans l'estimation du paramètre. C'est logique, si après avoir lancé deux fois une pièce nous obtenons deux fois face, il est raisonnable de se dire que cela est du à la chance et que la probabilité de face est enfait proche 0.5 comme nous le pensions a priori. Par contre si après 1000 lancers nous observons 600 faces, il est davantage raisonnable de supposer que la pièce n'est pas parfaitement équilibrée. Dans le cas présent, les paramètres α et β règlent la confiance que nous avons en notre prior, plus ils sont élevés, plus il faudra d'observations pour nous faire dévier (éventuellement) de notre prior.