TD 5 : Analyses de courbes - Feature maps

François Landes (et al.)

1 Analyse de courbes

Ces exercices visent à vous apprendre à savoir rapidement reconnaître quelques situations classiques, et plus généralement, à savoir analyser des comportements erratiques lorsqu'on fait de l'apprentissage statistique. Dans les figures ci dessous, on a toujours:

- En ordonnées la accuracy ou une autre mesure de la performance,
- En abscisse un hyper-paramètre, ou parfois le nombre d'époques (ou nombre d'itérations de descente de Gradient), parfois le nombre de features conservées après une réduction dimensionelle, bref, un hyper-paramètre que l'on peut contrôler, choisir.

Parfois, toutes les informations ne sont pas fournies, et c'est à vous de "deviner" certaines choses.

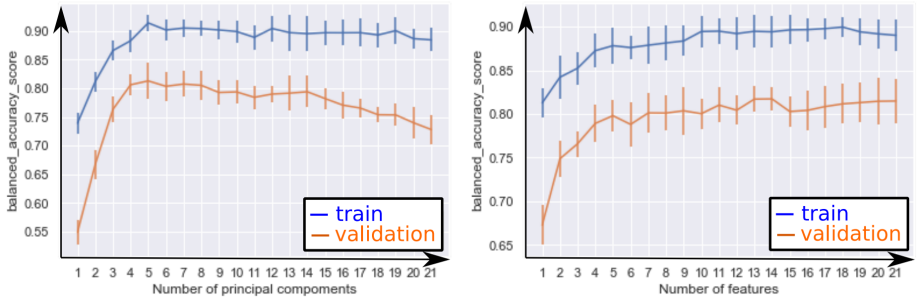

Figure 1: Ici l'hyper-paramètre en abscisse est le nombre de features conservées pour effectuer une classification. On peut supposer qu'une technique de réduction dimensionnelle (prochain cours) intervient en amont ou à l'inverse (figure de droite) que les features sont augmentées grâce à une feature map.

1.1 Comment interpréter les intervalles d'incertitude qui sont affichés ? À votre avis, comment ont-ils été calculés ?

1.2 Pour chacune de ces deux expériences, que concluez vous ? En particulier, quelle valeur de l'hyperparamètre (abscisse) choisiriez vous ? Justifiez bien la réponse (le raisonnement compte plus que le choix en lui même, plusieurs réponses sont admissibles). À quel point votre choix est il fait avec certitude ?

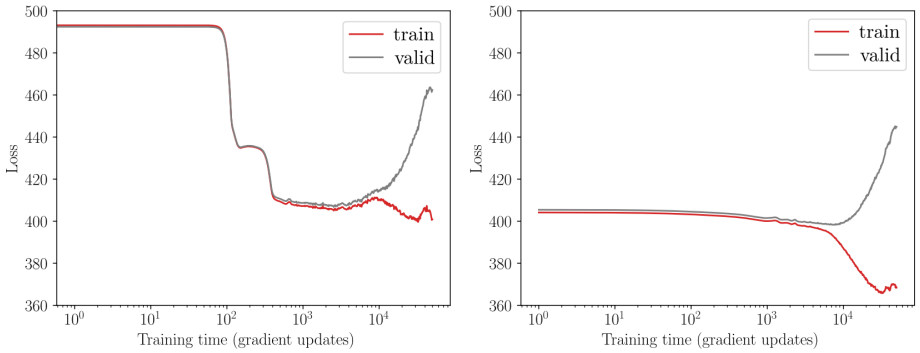

Figure 2: Ici l'axe des abscisse indique le nombre de pas de descente de gradient effectués. La loss est la fonction de perte, c'est-à-dire la fonction coût : plus elle est basse, mieux c'est.

2.1 Dans les deux cas ci-dessus, à quel instant de l'apprentissage vous arrêteriez vous?

2.2 Que peut-on remarquer concernant les axes des ordonnées des deux figures ? Quel est le meilleur des 2 modèles, en termes de performances uniquement ? (qualité du modèle obtenu)

2.3 Quel est l'autre avantage du modèle choisi ?

Source image : Merci Nicolas Béreux, article non publié.

Figure 3: Ici, on compare deux modèles différents (Random Forest (CM à venir) et Régression Linéaire), **qui visent à réaliser la même tâche**. L'abscisse n'est pas vraiment un hyper-paramètre, mais la taille du training set, c'est-à-dire le nombre de points de données utilisés pour la phase d'entraînement. Ce genre de courbe est appelée learning curve ou courbe d'apprentissage.

3.1 Qu'est ce que "MSE" (Mean Squared Error) ? C'est mieux quand c'est grand ou petit ? Quel type de tâche est on en train de traiter ?

3.2 Pour les deux modèles ci dessus, lequel choisiriez vous ?

3.3 Si on vous propose d'agrandir la taille de l'ensemble d'apprentissage, êtes vous intéressé(e) ?

3.4 Lequel des modèles semble être sous-paramétrisé (en situation d'underfitting, le contraire de l'over-fitting) ?

Source : https://www.dataquest.io/blog/learning-curves-machine-learning/

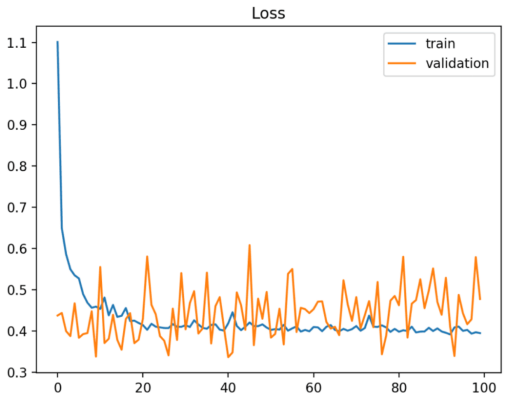

Figure 4: L'axe des abscisses est le nombre d'époques, et l'axe des ordonnées est la Loss.

4.1 Ci-contre, on a la l oss (train et validation) en fonction de l'époque. Au vu des fluctuations importantes de l'erreur de validation, que peut on dire sur la taille du validation set, par rapport à celle du training set ?

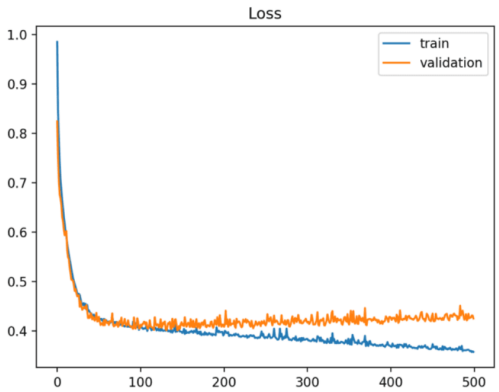

Figure 5: L'axe des abscisses est le nombre d'époques, et l'axe des ordonnées est la Loss.

5.1 A quel instant de l'apprentissage (quelle époque) vous arrêteriez vous ?

5.2 Quelle partie de l'entrainement correspond à de l'underfitting ? Overfitting ?

Source figure 4 et 5 : https://machinelearningmastery.com/learning-curves-for-diagnosing-machine-learning-model-performance/

2 Feature maps

Suivre le notebook TP5-FeatureMaps.ipynb